

Guía

October 19, 2025

1 Guía y reflexiones

Objetivo: dejar un paquete “listo para producción” que permita analizar el catálogo y desempeño (IMDb) de títulos, directores, actores y países, con calidad de datos trazable y un dashboard ejecutivo en **Tableau Public**.

1.1 1) Resumen ejecutivo (qué logramos)

- **Modelo analítico consistente:** esquema estrella con **dimensiones** de Título, Persona y País; **hechos** de ratings; puentes M:N para Personas y Países.
 - **Calidad medida y gobernada:** sin duplicados exactos; validaciones de rango, coherencias (p. ej., seasons solo en SHOW), y **gates** en ETL.
 - **Imputación responsable:** no forzamos temporadas; **cruce por title_norm + release_year** cuando hay datos en otras fuentes; si no, **mediana por género** para imdb_score/imdb_votes.
 - **Métricas definidas y reutilizables:** conteos únicos, promedios, **rating ponderado bayesiano** y segmentaciones (tipo, género, país, año).
 - **Dashboard** en Tableau: selector MOVIE/SHOW, **Top 5 géneros**, matriz género×año, **Top 5 & emergentes** (directores/actores), **donut de clasificación IMDb** (etiquetas traducidas), **mapa** por país y tarjetas clave.
-

1.2 2) Alcance y fuentes

- **Fuentes base (CSV):** dim_title.csv, dim_person.csv, dim_country.csv, fact_ratings.csv, bridge_title_person.csv, bridge_title_country.csv.
 - **Cobertura temporal:** últimos 20 años (filtro listo para usar en las vistas; el modelo conserva histórico).
 - **Limitaciones conocidas:** date_added no disponible; parte del imdb_id ausente; age_certification incompleto.
 - **Lineaje:** EDA → ETL (v3 countries) → salidas dimensionales → Tableau.
-

1.3 3) Hallazgos del EDA (lo que importa para el ETL)

- **Integridad:** 0 duplicados exactos por archivo; llaves title + release_year con **>99%** de cobertura.

- **Faltantes relevantes:** `imdb_score` y `imdb_votes` ~9% cada uno; `imdb_id` ~7–8%; `age_certification` alta ausencia.
- **No hubo match cruzado** (título+año) suficiente para completar `imdb_score/imdb_votes` desde auxiliares → **se justifica el fallback por género**.
- **Distribución:** `imdb_votes` con cola pesada (necesita log/winsor); **SHOW** suele puntuar un poco mejor que **MOVIE**; outliers manejables.
- **Coherencias:** `seasons` solo para **SHOW**; patrón `imdb_id` tipo `tt\d+`.

Implicación directa: el **ETL** debe (a) conservar el valor original, (b) intentar cruce por `title_norm + release_year`, y (c) si falla, imputar por **mediana del género**. `seasons_final` no se imputa.

1.4 4) Modelo de datos (estrella)

Hecho

- `fact_ratings`
 - Claves: `title_id` (FK → `dim_title`).
 - Métricas: `imdb_score_original`, `imdb_votes_original`, `imdb_score_final`, `imdb_votes_final`, `rating_ponderado`, etc.

Dimensiones

- `dim_title` (`title_id`, `imdb_id`, `title`, `title_norm`, `type` {**MOVIE**, **SHOW**}, `release_year`, `main_genre`, `age_certification`, `runtime_final`, `seasons_final`).
- `dim_person` (`person_id`, `name`).
- `dim_country` (`country_id`, `country_code`).

Puentes M:N

- `bridge_title_person` (`title_id`, `person_id`, `role`).
- `bridge_title_country` (`title_id`, `country_id`).

Notas de modelado

- Las tablas **bridge** evitan duplicar títulos/personas y permiten **contar distintos** en BI.
 - Reglas de conteo:
 - **Títulos por director:** `COUNTD(title_id)` filtrando `role="DIRECTOR"`.
 - **Títulos por actor:** `COUNTD(title_id)` filtrando `role="ACTOR"`.
 - Al cruzar con países: usar `COUNTD(title_id)` para no inflar por coproducciones.
-

1.5 5) Decisiones de ETL y *quality gates*

Limpieza & normalización

- `title_norm`: minúsculas, sin acentos, sin signos → mejor *join* por título+año.
- Tipificación numérica segura (`to_numeric(errors="coerce")`); patrón `imdb_id` válido.
- `character` vacío en actores → **“desconocido”** (no se pierde el registro).

- No eliminar `imdb_id` en actores/títulos (necesario para BI y trazabilidad).

Imputación

1. **Cruce:** si existe la misma (título_norm, año) en otro dataset con `score/votes` → usar ese valor.
2. **Fallback:** si no hay donante, **mediana por main_genre**.
3. `seasons_final = seasons` (sin imputar; coherente con `type=SHOW`).

Quality gates (bloquean el pipeline)

- `imdb_score_final` fuera de `[0..10]` → **fail**.
- `runtime_final` fuera de `[1..600]` → **warn/fix** (cap/winsor).
- `seasons_final` no nulo con `type SHOW` → **fail**.
- `release_year` en futuro → **fail**.

Performance

- Categorización para `type`, `main_genre`, `country_code` → menor memoria.
- *Seeds* y logs para reproducibilidad.

1.6 6) Métricas y KPIs (definiciones)

- **Títulos:** `COUNTD(title_id)`.
- **Prom IMDb:** `AVG(imdb_score_final)`.
- **Votos IMDb:** `SUM(imdb_votes_final)`.
- **Rating ponderado (Bayes)**, evitando sesgo por pocos votos:

$$\text{rating_ponderado} = (v / (v + m)) * s + (m / (v + m)) * C$$

- `s`: `imdb_score_final` del título
- `v`: `imdb_votes_final` del título
- `C`: promedio global de `imdb_score_final` (o por filtro actual)
- `m`: umbral de estabilización (p. ej., p90 de votos o un valor de negocio)

En Tableau: implementarlo como calculadas anidadas todas a nivel de **fila del título** o como **LOD FIXED** para `C/m`.

1.7 7) Dashboard — diseño y uso

Controles

- **Botones MOVIE/SHOW** (parámetro + acción o filtro de dimensión).
- Filtros: Años (últimos 20 por defecto), Género, País.

Vistas

1. **Top 5 géneros** (barra horizontal, `COUNTD(title_id)`).
2. **Matriz género × año** (círculos; tamaño por `COUNTD(title_id)` y color por tendencia).

3. Top 5 directores y emergentes (6–10)

- Cálculo: `COUNTD(title_id)` filtrando `role="DIRECTOR"`, ordenar y limitar (`Index/Rank`).

4. Top 5 actores y emergentes (6–10) (igual, `role="ACTOR"`).

5. Donut IMDb por `age_certification`

- **Traducciones** (ejemplos): G Apta para todo público · PG Guía paterna · PG-13 13+ · R Restringida (menores de 17 con adulto) · NC-17 Solo adultos · TV-Y Niños · TV-G General · TV-PG Guía paterna · TV-14 14+ · TV-MA Adultos (17+) · NR/UR Sin clasificación.
- Mostrar %: formato de número **Porcentaje** con 0–1 decimales.

6. Mapa por país (de `dim_country` vía `bridge_title_country`), medida `COUNTD(title_id)`.

Interacción

- Clic en **Top 5 géneros** filtra el resto; botones **MOVIE/SHOW** influyen en todas las vistas; tooltip con `rating_ponderado`, votos y año.
-

1.8 8) Riesgos, supuestos y mitigación

- **M:N y doble conteo**: siempre usar `COUNTD(title_id)` al cruzar Personas y Países.
 - **Valores faltantes**: la mediana por género evita sesgo; documentar tasa de imputación.
 - **Sesgo por pocos votos**: usar `rating_ponderado` en listados “Top”.
 - **Campos no disponibles**: `date_added` fuera de alcance; si se incorpora, añadir **tabla de fechas** y snapshot.
-

1.9 9) Recomendaciones de siguiente iteración

1. **Enriquecer** `imdb_id` y `age_certification` con fuentes externas (OMDb/IMDb datasets).
 2. **Matching difuso** (fuzzy) para mejorar el cruce por título.
 3. **Segmentar m** (umbral bayesiano) por tipo o género.
 4. **Pruebas automatizadas** del ETL (`pytest` + `great_expectations`) y **CI** en Git.
 5. **Semántica común** (definiciones de KPI) en un **Diccionario de Métricas** compartido.
-

1.10 10) Glosario (variables clave del ETL)

- **imdb_score_final**: puntuación consolidada (original, o imputada por **mediana del género** si faltante).
- **imdb_votes_final**: votos consolidados (original, o **mediana del género** si faltante).
- **rating_ponderado**: score estabilizado mediante promedio global **C** y umbral **m**.
- **title_norm**: normalización de `title` (minúsculas, sin acentos/ruido) para cruces.
- **main_genre**: género dominante del título (base para imputación segmentada).
- **seasons_final**: temporadas; **no imputada**; solo aplica a **SHOW**.
- **bridge_title_person**: puente M:N entre título y persona (roles: **ACTOR/DIRECTOR/...**).

- **bridge_title_country**: puente M:N entre título y país (coproducciones).
-

1.11 Reflexiones finales

El proyecto expone un balance entre **rigor analítico** y **practicidad de negocio**. Del lado de datos, priorizamos una imputación **parsimoniosa**: primero intentamos recuperar información por cruce (**title_norm** + **release_year**) y solo en ausencia de donantes aplicamos **mediana por género**. Esta decisión limita el sesgo y mantiene la interpretabilidad, dos rasgos críticos cuando las métricas alimentan decisiones visibles (e.g., rankings de contenido, mejores directores/actores).

En modelado, la elección de un **esquema estrella** con puentes M:N, más el uso sistemático de **COUNTD(title_id)**, reduce el riesgo de **doble conteo** al cruzar personas y países. La experiencia mostró que pequeños desalineamientos en granularidad (episodios vs. obras) pueden inflar indicadores; por ello consolidamos claves (**imdb_id**, **title_id**, **work_key** cuando aplique) y verificamos con hojas de control en BI. Esta disciplina —sumada a *quality gates* explícitos— fortalece la **confiabilidad del insight** y habilita auditoría.

Del lado de consumo, evitamos sobre-ingeniería: el dashboard comunica con **pocas vistas potentes** (matriz género×año, Top & Rising, donut de clasificación, mapa) y controles mínimos (botones MOVIE/SHOW, filtros de año/género/país). El objetivo es que un usuario de negocio **entienda y actúe** en segundos, sin leer un manual. Cuando haya que profundizar, el **rating ponderado** ofrece una métrica robusta para comparaciones “justas” frente a volúmenes de votos muy dispares.

Finalmente, dejamos un camino claro de **evolución**: enriquecer **imdb_id** y **age_certification**, introducir *matching* difuso, y automatizar validaciones con *data tests*. Esto permite escalar el caso de uso (más catálogos, más mercados) manteniendo la **coherencia semántica** y la **trazabilidad**.